



张振杰

☎电话: 15703473885

✉邮箱: 15703473885@163.com

♂性别: 男

📅开始工作时间: 2024

📅工作年限: 2

📅到岗时间: 一周内

📅期望薪资: 14k-17k

🎓 教育经历

2020.9-2024.6

山西大学(双一流)

软件工程 | 本科

主修课程: 面向对象程序设计、数据结构与算法、数据库概论、计算机网络、操作系统

💼 工作经历

2024.6-2026.8

西安因联信息科技有限公司

AI 大模型开发工程师

任职西安因联信息工业 AI 应用开发工程师, 依托企业设备运维业务数据底座开展大模型应用落地, 搭建运维场景 RAG 知识库并完成私有化离线部署, 搭建多智能体协同分析能力, 对接 MES 多系统数据流实现产线质量告警根因分析与处置方案输出, 通过对照实验完成整套 AI 应用落地验证。

📁 项目经历

2025.11-2026.07

异常事件多 Agent 根因分析系统

技术栈: LangGraph、LangChain、Qwen3.5-14B、BM25、BGE-large-zh、BGE-Reranker、Checkpointner、Milvus、Redis、Celery、RESTful API 集成、Excel 解析、Docker Compose

一、项目简介

面向某大型制造企业生产现场日均 120-200 条异常事件, 根因数据分散在 6 个异构系统。设计并实现基于 LangGraph 的多 Agent 智能分析系统, 通过动态路由与多 Agent 协同, 实现异常根因自动定位与处置方案智能生成, 将根因定位时间从 2-4 小时缩短至 18 分钟。

二、个人职责

1、多 Agent 编排与工具抽象: 独立设计基于 LangGraph 的五状态机 (异常理解→调度决策→根因分析→处置决策→合规归档), 实现三路动态路由 (复用 55%/全链路 45%/回退<5%), 通过 Checkpointer+Redis 持久化支持断点恢复。封装 6 个异构数据源 (MES/ERP/WMS/OA/Excel/PLM), 完成 API 适配与编码归一化, Agent 工具调用顺序由 LLM 自主决策。核心编排模块单元测试 58 个, 覆盖率 85%, 纳入 CI 流水线。

2、RAG 检索体系: 规划三个知识库 (历史案例库 12000 条/工艺规则库 2000 条/设备-物料关联库 5000 条), 实现 BM25+稠密检索双路召回+BGE-Reranker 重排序, 针对精确数值与模糊描述查询动态调权。设计检索链路 4 节点日志埋点和分库路由策略, 通过 trace_id 实现全链路追溯。自建 2000 条评测集, Recall@3 从 0.61 提升至 0.83。

3、HitL 挂起与三层容错降级: 基于 LangGraph 原生中断实现低置信度人工介入与断点恢复, 双因子门控 (置信度<0.65 且证据覆盖<70%) 最多回退 1 次。三层兜底覆盖自动重试、Agent 降级与系统兜底; 另设 ReAct 死循环防护 (最大 8

次工具调用/30 秒超时/连续 3 步无新证据触发自检) 和跨系统数据一致性保障。高危操作强制二次人工确认。

4、**知识飞轮与算力调度**：设计案例自动入库流程（闭环判定→日志提取→LLM 生成草稿→人工抽检→向量去重），入库质量保障包括相似度>0.95 自动合并、噪声率监控、72 小时效果验证。案例库从 4800 条增长至 11500 条，Top5 命中率从 81%提升至 87%。Redis+Celery 异步队列实现削峰填谷与优先级调度；llm_factory 抽象层使基座模型升级时推理逻辑零修改。

三、项目成果

1、**根因定位效率**：单异常根因定位时间从人工 2-4 小时缩短至 18 分钟，根因定位准确率从单 Agent 基线 76%提升至 87%（自建 2000 条评测集，经质量工程师标注验证），单月累计节约工程师工时约 950 人时。

2、**重复告警消化**：人工干预率从 100%降至 13%，重复告警自动消化率达 55%（需人工介入的重复告警占比从 42%降至 14%），质量团队从全量处理转向审核确认与疑难攻关。

3、**知识持续沉淀**：知识飞轮使案例库从 4800 条增长至 11500 条，RAG Top5 命中率从 81%提升至 87%，老工程师经验沉淀为系统能力，降低了人员流动带来的能力断层风险。

4、**工程可维护性**：核心编排模块单元测试覆盖率达 85%（58 个用例），纳入 CI 流水线；llm_factory 抽象层使基座模型升级时推理逻辑零修改，后续模型迭代成本显著降低。

2025.3-2025.10

制造企业智能运维知识库系统

技术栈：Flask、BGE-M3、BM25、BGE-Reranker、Milvus、MySQL、Redis、Ollama(Qwen2.5:7B)、RRF（融合策略）、PaddleOCR、Docker Compose

一、项目简介

面向某机加工企业 200 余台数控设备运维场景，针对故障诊断高度依赖老师傅经验、新工程师培养周期长达 18 个月的痛点，设计并实现基于 RAG 架构的智能运维知识库系统，通过多路召回与自校验机制实现故障分钟级诊断，将故障定位时间从 2 小时缩短至 10 分钟，新工程师培训周期缩短至 6 个月。

二、个人职责

1、**三层检索架构**：独立设计 L1-Redis（高频<50ms）、L2-MySQL 精确匹配（<100ms）、L3-Milvus 混合检索级联链路，本人独立负责 L3 层：BM25+BGE-M3 双路召回+BGE-Reranker 精排，设计 RRF 融合策略。自建 500 条工业故障评测集，Recall@5 从 0.72 提升至 0.89，P99 响应稳定在 2.8s 以内，日均支撑 300+次查询。

2、**文档解析与结构化**：主导设备手册解析，编写正则章节识别器按“章-节-条-款-表”切分，设计元数据注入支持父级上下文回溯；引入 PaddleOCR 识别图纸报警标识，提取故障-现象-原因三元组存入 MySQL，累计处理手册 1800 余页。

3、**Query Rewrite 与动态路由**：利用 Qwen2.5:7B 将口语化描述转为标准化术语，设置相似度<0.6 自动回退原始查询，避免改写引入噪声。设计直接检索、HyDE、子查询分解、回溯简化四种策略的动态路由，复杂场景召回率较单一策略提升 18%。

4、**自校验与知识沉淀**：设计生成端反射自校验，基于 BGE-Reranker 逐句核对事实一致性，无据论断打回重写，强制附带来源编号，错误引用率从 12%降至 2%以下。设计工单结案自动沉淀流程，参与搭建运维看板（故障热力图/知识覆盖率趋势/人工干预量变化）。上线 3 个月知识覆盖率从<50%提升至>80%，沉淀有效知识 1200+条。

三、项目成果

1、**故障定位提效**：故障定位时间从平均超 2 小时缩短至约 10 分钟，维修方案匹配准确率从基线 68%提升至 89%（基于自建 500 条标注测试集，涵盖 200 余种设备故障类型），大幅减少设备停机损失。

2、**缓存命中与响应**：L1 热缓存命中率超 50%，整体 P99 响应时间稳定在 2.8s 以内，日均支撑 300+次查询，有效缓解高频查询对检索层的并发压力。

3、**知识沉淀与合规部署**：系统基于 Docker Compose 实现一键私有化部署，数据完全留存企业内网，满足制造业数据

合规要求；上线 3 个月累计沉淀有效知识 1200+条，知识覆盖率从不足 50%提升至 80%以上。

4、**培训与可信度**：新工程师培训周期从 18 个月缩短至 6 个月以内；错误引用率从抽检 12%降至 2%以下，生成答案的可用性和可信度显著提升。

2024.06-2025.03

占位

技术栈：BERT、BERT+CRF、ALBERT-Tiny、多任务学习、半监督学习、对比学习、知识蒸馏、ONNX、INT8 量化、TensorRT、Chroma

一、项目简介

面向企业数字化客户的 NLP 能力中台首个落地场景，解决通用大模型在合同法律文本上语义理解偏差大、标注数据稀缺（<2000 条）、推理成本高三大痛点。系统支持合同类型分类、关键要素抽取、风险条款智能识别与语义检索。

二、个人职责

1、**领域模型训练与合同分类**：在 10 万+无标注合同语料上进行领域数据继续训练（Further Pretraining），使 BERT 充分适应法律术语与句式结构，经 FP 后精调，12 类合同分类准确率从 FastText 基线的 85%提升至 93.2%，较通用 BERT 直接精调提升 5.3 个百分点。选型决策：不依赖大模型 API 做标注，因合同数据涉及企业隐私，全部本地完成。

2、**多任务学习与低资源 NER**：在 NER 任务上引入段落类型分类作为辅助任务，利用合同结构化特征辅助实体识别，F1 较单任务提升 3.1 个百分点。面对标注样本稀缺（<2000 条）的业务约束，独立设计伪标签半监督学习+对比学习联合训练框架，充分利用无标注领域文本，标注成本降低 80%，NER 模型性能保持全量标注的 92%。

3、**风险要素抽取与规则引擎**：基于 BERT+CRF 实现违约金金额、管辖法院、保密期限等 8 类风险条款自动抽取，解决长文本实体嵌套与跨句边界问题，F1 达 86.7%。搭建 12 条风险规则引擎（覆盖赔偿条款/管辖权/知识产权归属等高频风险点），与 NER 抽取结果串联校验——NER 召回候选风险字段，规则引擎二次过滤与风险定级，高置信度结果可直接出报告。

4、**模型压缩加速与语义检索**：采用知识蒸馏（BERT→ALBERT-Tiny，1.1 亿→1500 万参数），精度衰减<2%；结合 ONNX 导出+INT8 量化+TensorRT 推理加速，单次推理延迟从 78ms 降至 8ms（CPU 单核），QPS 提升近 10 倍，模型体积减小 90%+，支持纯 CPU 低成本部署。选型决策：不走在线 API 而选本地部署，客户合同数据不能出内网，纯 CPU 方案硬件成本降 85%以上。将 BERT 编码的合同文本向量存入 Chroma，构建语义检索引擎，相似条款检索 Recall@10 达 91%，为后续 RAG 链路提供向量化基础。

三、项目成果

1、分类与抽取精度：合同分类准确率达 93.2%，风险条款抽取 F1 达 86.7%，经 3 个月持续迭代生产环境准确率从 89%提升至 93.2%。

2、标注成本降低：半监督+对比学习框架使标注成本降低 80%，NER 模型性能保持全量标注的 92%。

3、模型压缩与推理加速：模型体积压缩 90%+，单次推理延迟从 78ms 降至 8ms（CPU 单核），QPS 提升近 10 倍，纯 CPU 部署硬件成本降低 85%以上。

4、业务落地规模：系统累计处理合同 15 万+份，精准识别高风险条款 2.3 万条，语义相似条款检索 Recall@10 达 91%。

99 自我评价

2 年 AI 大模型应用开发经验,具备工业大模型应用开发实战经验，熟悉 RAG 知识库构建、多智能体应用开发以及私有化大模型部署落地。有制造行业业务认知，熟悉 MES、设备运维业务场景，能够完成多系统数据对接、业务需求到 AI 应用落地全流程。注重工程实践，擅长结合业务痛点设计解决方案，代码落地能力扎实，学习主动性强，能够快速适配工业项目交付场景。

相关技能

- **模型训练与微调**：PyTorch、Transformers、QLoRA、DAPT 领域预训练、多任务学习、半监督学习、对比学习
- **RAG 与知识检索**：LangChain、Neo4j、Chroma、HyDE、BGE-Rerank、Function Calling
- **模型压缩与部署**：知识蒸馏、ONNX、INT8 量化、TensorRT、FastAPI、Docker
- **多模态**：MobileNetV3、双塔融合架构、图像 + 文本跨模态联合推理
- **NLP**：文本分类、命名实体识别（BERT + CRF）、序列标注、BIO 标注体系
- **工程与数据处理**：Python、Pandas、Redis、Celery、Git

荣誉证书

普通话一级乙等、大学英语 4 级